

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ

ГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ  
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ  
"МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ  
(ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ)"

ФАКУЛЬТЕТ ИННОВАЦИЙ И ВЫСОКИХ ТЕХНОЛОГИЙ  
КАФЕДРА АНАЛИЗА ДАННЫХ

---

Выпускная квалификационная работа по направлению

01.03.02 «Прикладная математика и информатика»

НА ТЕМУ:

**АЛГОРИТМЫ КОНСЕНСУСА НА ЭНЕРГОНЕЗАВИСИМОЙ ПАМЯТИ  
ПРОИЗВОЛЬНОГО ДОСТУПА**

Студент

Сурин М.С.

Научный руководитель к.ф-м.н

Бабенко А.В.

Зам. зав. кафедрой д.ф-м.н, проф.

Бунина Е.И.

МОСКВА, 2017

# Оглавление

|          |                                       |           |
|----------|---------------------------------------|-----------|
| <b>1</b> | <b>Введение</b>                       | <b>2</b>  |
| 1.1      | NVDIMM . . . . .                      | 2         |
| 1.2      | Обзор литературы . . . . .            | 3         |
| <b>2</b> | <b>Цель работы</b>                    | <b>4</b>  |
| 2.1      | Постановка задачи . . . . .           | 4         |
| 2.2      | Метрики . . . . .                     | 4         |
| 2.3      | Бейзлайн . . . . .                    | 5         |
| <b>3</b> | <b>Постановка эксперимента</b>        | <b>7</b>  |
| 3.1      | Инструменты . . . . .                 | 7         |
| 3.2      | Структуры данных . . . . .            | 8         |
| 3.3      | Управление памятью . . . . .          | 9         |
| 3.4      | Алгоритм . . . . .                    | 11        |
| <b>4</b> | <b>Результаты</b>                     | <b>12</b> |
| 4.1      | Тесты алгоритмов консенсуса . . . . . | 12        |
| 4.2      | Тесты структур данных . . . . .       | 13        |
| <b>5</b> | <b>Заключение</b>                     | <b>14</b> |

# Часть 1

## Введение

### 1.1 NVDIMM

Дизайн СУБД всегда был вынужден принимать во внимание принципиальную разницу между энергозависимыми устройствами хранения информации и энергонезависимыми. Разница проявляется как в латентности доступа, так и в особенностях предоставляемого интерфейса. Энергонезависимые устройства как правило предоставляют блочный интерфейс, то есть позволяют оперировать только блоками из тысяч байт. В то время как современные DIMM дают возможность оперировать словами – единицами байт. Но не так давно (2014-15гг) появились на рынке технологии под общим названием “NVDIMM”, занимающие некое промежуточное звено сохраняя данные при потере питания, предоставляя скорость доступа, сравнимую с DRAM и также давая возможность адресации отдельных байтов.

Большая часть продуктов на 2014г (например продукты Micron Technology) представляют из себя модуль DRAM служащий кешем для модуля энергонезависимой памяти (как правило NAND FLASH) и автономным источником питания. Но тогда же были анонсированы, а позже и появились на рынке устройства без подобного разделения – к примеру Intel Optane NVDIMM [15].

Порядки времён доступа к промышленным устройствам:

|        | SSD   | NVDIMM | DIMM |
|--------|-------|--------|------|
| чтение | 200us | 120ns  | 80ns |
| запись | 2ms   | 750ns  | 80ns |

Такая небольшая разница между быстрой оперативной памятью и медленной

энергонезависимой даёт возможность пересмотреть традиционные подходы к дизайну и архитектуре СУБД в перспективе давая возможность добиться большей производительности.

## 1.2 Обзор литературы

Несмотря на отсутствие на рынке устройств, исследователи давно пытаются оптимизировать алгоритмы [11] и структуры данных [5] для персистентной памяти. Многие из них пользуются либо программными платформами для эмуляции задержек NVDIMM [17] либо занимаются построением аппаратных моделей [7]. Использование персистентной памяти ставит перед исследователями новые задачи, такие как менеджмент памяти [16]. Также своя специфика есть у задачи обеспечения целостности данных при потере питания, так как большинство современных процессоров кешируют доступы к памяти и практически не предоставляют примитивов для управления своим кешем. Как следствие для работы с персистентной памятью появились отдельные библиотеки такие как PMDK [10] и api [12]. Задачей построения архитектуры СУБД, занимается удивительно малое количество исследователей и в основном можно выделить исследователей из Carnegie Mellon School of Computer Science [14], [2], [6], [1], [3]. В [3] приведена альтернатива write-ahead logging для NVM, позволяющая повысить производительность СУБД и рассмотрена задача репликации с учётом NVM, но задача координации не рассматривалась. Задачей исследования алгоритмов консенсуса для NVM по нашим сведениям никто не занимался.

## Часть 2

# Цель работы

### 2.1 Постановка задачи

Мы рассматриваем алгоритмы консенсуса с точки зрения задачи репликации состояния конечного автомата. Состояние будет представлять из себя ассоциативный массив, ключами и значениями выступают произвольные последовательности байт. Зафиксируем интерфейс, достаточный для большинства прикладных задач:

- $\text{get}(key)$  – операция чтения значения по ключу
- $\text{set}(key, value)$  – операция записи значения по ключу
- $\text{compare\_and\_set}(key, value_1, value_2)$  – операция обновления значения по ключу  $key$  на  $value_2$  в случае если оно до операции равно  $value_1$

От алгоритмов будем требовать линеаризуемости [8] истории операций в условиях наличия нарушений связности сети.

### 2.2 Метрики

При экспериментах мы изучаем следующие характеристики:

- латентность записи (то есть операций  $\text{set}$  и  $\text{compare\_and\_set}$ )
- скорость восстановления отставших реплик

В большинстве прикладных реализаций алгоритмов репликации операции чтения осуществляются лидером без задействования реплик из оперативной памяти. А значит, от алгоритмов оптимизированных для NVM нет поводов ожидать улучшений латентности чтения. Поэтому в нашей работе данную метрику не исследуем.

## 2.3 Бейзлайн

В качестве эталонной реализации мы используем реализацию алгоритма RAFT [13] использующую NVDIMM как блочное устройство хранящую на ней write-ahead log и снимки состояния.

Напомним некоторые детали общей схемы работы данного алгоритма: Алгоритм реплицирует состояние некоторого конечного автомата. Каждое изменение состояния получает уникальный номер от лидера – далее timestamp. После этого изменение пересылается репликам. Реплики в некотором виде отказоустойчиво сохраняют изменения и отправляют лидеру timestamp последнего сохранённого изменения и timestamp следующего ещё не полученного от лидера изменения. Лидер применяет изменение к своему состоянию после подтверждения того что оно сохранено более чем половиной участников. Лидер и реплики периодически обмениваются сообщениями и в случае неполучения такого сообщения в течение некоторого временного периода реплики инициируют перевыборы лидера. При выборах каждый участник пересылает предложение о голосовании за себя остальным, включая в него номер последнего сохранённого сообщения. В случае получения предложения с меньшим номером чем у получателя предложение отвергается. Новым лидером становится реплика, за которую проголосовало более половины участников. До того как приступить к обслуживанию запросов новый лидер рассылает и после применяет все свои изменения. Изменения на репликах, отличающиеся от изменений полученных от лидера, при нахождении удаляются вместе с последующими сохранёнными соответствующей репликой.

Также были реализованы следующие оптимизации не меняющие принципиальной схемы работы:

- heartbeat осуществляется без задержки при клиентском запросе на запись
- сброс write-ahead log на диск осуществляется фоновым процессом, но при об-

работке клиентских запросов лидером и обработке heartbeat репликами происходит без задержки.

## Часть 3

# Постановка эксперимента

### 3.1 Инструменты

Все эксперименты проводились в операционной системе Linux. Для прикладного использования на данной платформе NVDIMM после предварительной разметки и настройки представляет собой блочное устройство. Для использования в качестве памяти предполагается создание файла с помощью `fallocate` и его отображение в виртуальную память с помощью `mmap`. Файловая система при этом должна предоставлять режим DAX, отключающий `page-cache`. Мы в частности использовали Ext4. После вышеописанных шагов модификации выделенного пространства на NVDIMM не требуют системных вызовов и не задействуют ядро операционной системы.

Записи в NVDIMM кешируются процессором. Для отказоустойчивой записи необходимо вытеснить соответствующие участки памяти из кэша одной из инструкций `clflush/clflushopt/clwb` и подождать барьер записи – например выполнить инструкцию `sfence`. При этом механизмов предотвращающих преждевременное вытеснение памяти из процессорного кэша нет. NVDIMM при этом гарантирует атомарность модификации участков памяти, соответствующих кеш-линиям.

В своих экспериментах мы используем библиотеку PMDK, предоставляющую коллекцию базовых примитивов для работы с персистентной памятью. К примеру такие как указатели на персистентную память, механизм выделения памяти и транзакции в персистентной памяти. О них мы и поговорим подробнее.

В силу механизма отображения персистентной памяти в виртуальную, персистентная память может быть доступна прикладным программам с разным сме-



щением в разных запусках. А значит, при необходимости использования ссылок на персистентную память необходимо оперировать не указателями, а смещениями внутри персистентного региона памяти.

Задача управления персистентной памятью также имеет свою специфику: выделение памяти и запись ссылки на неё в уже выделенную область памяти должны происходить атомарно, так как при пропаже питания между этими двумя действиями может образоваться утечка памяти. Утечки персистентной памяти наносят гораздо больший вред чем утечки оперативной, так как не исчезают после перезапуска программы. Механизм выделения памяти в PMDK использует транзакции.

Транзакция в персистентной памяти это атомарное изменение нескольких участков памяти. Отдельно подчеркнём что мы говорим не про атомарность изменения для других процессорных ядер, а про атомарность изменения в случае сбоя питания. Обобщённая схема механизма транзакций в PMDK такова:

1. модифицируемые регионы копируются в `undo log` – примитив реализованный в библиотеке `libpmemlog`.
2. модифицируются исходные участки памяти
3. удаляется запись из `undo log`

На каждом из шагов все записи отказоустойчиво фиксируются в персистентной памяти (то есть вытесняются из процессорного кеша и ожидается барьер записи).

## 3.2 Структуры данных

Для уменьшения латентности записи мы отказываемся от `write-ahead log` и модифицируем структуры данных сразу при обработке пользовательских запросов лидером и обработке `heartbeat` репликами. Все структуры данных в наших экспериментах в том или ином виде реализуют отсортированный ассоциативный массив. Мы пользуемся MVCC [4] храня несколько версий значений – ключами в этом массиве выступают пары (пользовательский ключ, `raft timestamp`). Также для каждой неподтверждённой кворумом транзакции мы храним запись для отката со списком указателей на её ключи. Ключ для каждой такой записи имеет вид (зарезервированная строка,

timestamp транзакции). Для операции  $get(x)$  мы выполняем поиск наибольшего ключа не превосходящего  $(x, applied\_ts)$  где  $applied\_ts$  – номер последней применённой транзакции в терминах raft. Для операции  $compare\_and\_set(x, value_1, value_2)$  соответственно выполняем поиск максимального ключа вида  $(x, y)$ .

При работе алгоритма лидер хранит в DRAM некоторое небольшое количество записей соответствующих последним обработанным транзакциям для пересылки репликам. Следуя общей схеме алгоритма RAFT лидер с некоторой периодичностью пытается переслать эти записи репликам. В случае значительного отставания какой-либо реплики, она не может принять записи из вышеописанного буфера, так как получала промежуточных записей от лидера. Для эффективного решения задачи восстановления таких реплик все реализованные нами структуры данных имеют механизм снимков состояния для последующей пересылки отставшей реплике состояния лидера целиком.

В качестве структуры данных реализующей ассоциативный массив мы пробовали персистентные B+ деревья. В наших тестовых сценариях размер базы составлял сотни тысяч ключей и оптимально с точки зрения производительности себя показали деревья с фактором ветвления 4-7.

Также были реализованы персистентные односвязные списки. Для ускорения операций чтения в DRAM поддерживается сбалансированное дерево поиска со ссылками на вершины данного списка. Модификации (как записи так и удаления) в данной структуре данных реализованы добавлением в конец списка и соответствующими модификациями дерева в DRAM. Подчеркнём сходство данной схемы с классическим write-ahead log. Ключевое отличие данной структуры данных в возможности очистки такого списка от дубликатов ключей фоновым процессом без блокировки процесса чтений и модификаций и значительной нагрузки на устройство хранения. Снимком данной структуры данных является односвязный список. В нашей реализации взятие снимка блокирует процесс очистки структуры данных от дубликатов.

### 3.3 Управление памятью

Как упоминалось в 3.1, управление персистентной памятью представляет из себя нетривиальную задачу. В отличие от PMDK мы реализовали систему с авто-

матической сборкой мусора. Так как все реализованные структуры являются персистентными, это позволяет не вытеснять данные из кеша при каждой модификации структуры данных, а делать это для групп модификаций. Здесь подчеркнём что мы можем позволить себе гораздо меньшие размеры таких групп чем в случае использования write-ahead logging. Более того, персистентность структур данных даёт возможность реализации неблокирующих алгоритмов сборки. Далее опишем общую схему реализации.

При инициализации базы мы размечаем всю доступную персистентную память на страницы – в наших тестах оптимально себя показали размеры порядка 1К. В начале каждой страницы находится контрольный блок – указатель на свободную память в этой странице и указатель на следующую в односвязном списке страниц. Кроме страниц в персистентной памяти находится общий контрольный блок с указателями на списки занятых и полностью свободных страниц соответственно и указателем на одну из реализаций ассоциативного массива приведённых в 3.2. При выделении памяти либо сдвигается указатель в странице из головы списка “занятых” страниц, либо перемещается страница из списка свободных в список занятых и также сдвигается указатель. Операции со списками выполняются с помощью примитива транзакций из PMDK, операции с указателями выполняются без вытеснения из процессорного кеша. Для подтверждения записи группы модификаций (и соответственно аллокаций) выполняется вытеснение из кеша указателей всех задействованных страниц и участков памяти, соответствующих модификациям и ожидается барьер записи в NVDIMM. После этого аналогично обновляется указатель на структуру данных в контрольном блоке.

Для сборки мусора достаточно произвести обход структуры соответствующую указателю из контрольного блока и построить пересечение со списком использованных страницы из контрольного блока. Все страницы кроме головы списка, не вошедшие в пересечение перемещаются в список свободных. Модификации и соответственно чтения для сборки мусора из контрольного блока защищены мьютексом в оперативной памяти. В реализации персистентного списка из 3.2 во время сборки мусора также производится дедупликация записей в списке.

В 4.2 находятся результаты сравнения наших алгоритмов, построенных на данной схеме с алгоритмами из `rmemkv` [9].

## 3.4 Алгоритм

Схема работы нашего алгоритма повторяет описанную в [13]. Удалению записей соответствуют откаты из нашего ассоциативного массива с помощью дополнительных записей описанных в 3.2. Состоянию конечного автомата отвечает срез множества ключей по применённому timestamp хранимому в DRAM. Модификации структуры производятся в момент обработки клиентского запроса лидером и получения новых записей репликами. Фиксация на NVDIMM, описанная в 3.3 осуществляется каждые  $k$  модификаций и с некоторой частотой. В наших тестах оптимальными оказались  $k = 10$  и частота 1us. В момент увеличения применённого timestamp в терминах RAFT лидером отправляется подтверждение клиенту и после удаляются старые версии значений ключей из ассоциативного массива а также записи для отката соответствующих изменений. Фиксация удалений перед подтверждением не ожидается.

При восстановлении отставшей реплики пересылается полный снимок структуры данных. Номера применённого timestamp и последнего содержатся в снимке.

## Часть 4

# Результаты

### 4.1 Тесты алгоритмов консенсуса

Эксперименты производились на Intel Optane DC Persistent Memory. Размер базы в экспериментах – 50000 ключей. Ключи и значения занимают порядка 10 байт.

Далее WAL – классическая реализация raft, описанная в 2.3. list – реализация персистентного списка, описанная в 3.2 и btree – с персистентными B+ деревьями (приведены тесты для 4-7 детей).

Для выяснения минимальной возможной латентности мы проводили эксперименты в которых системе задавались запросы последовательно, каждый после того как получен ответ на предыдущий запрос На одной машине (без сетевых задержек) медиана времени ответа:

| WAL   | List  | btrees |
|-------|-------|--------|
| 150us | 100us | 120us  |

На разных машинах (с сетевыми задержками):

| WAL   | List  | btrees |
|-------|-------|--------|
| 257us | 230us | 250us  |

Также аналогичные тесты проводили с 20 потоками задающими запрос.

На одной машине

| квантиль | WAL   | List  | btrees |
|----------|-------|-------|--------|
| 0.5      | 560us | 412us | 480us  |
| 0.9      | 800us | 650us | 780us  |

На разных машинах:

| квантиль | WAL    | List  | btrees |
|----------|--------|-------|--------|
| 0.5      | 720us  | 610us | 700us  |
| 0.9      | 1120us | 800us | 1020us |

Время ответа на операции чтения ожидаемо оказалось одинаковым в пределах погрешности.

## 4.2 Тесты структур данных

## Часть 5

## Заключение

# Литература

- [1] Joy Arulraj and Andrew Pavlo. How to build a non-volatile memory database management system. In *Proceedings of the 2017 ACM International Conference on Management of Data*, pages 1753–1758, 2017.
- [2] Joy Arulraj, Andrew Pavlo, and Subramanya R Dulloor. Let’s talk about storage & recovery methods for non-volatile memory database systems. In *Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data*, pages 707–722, 2015.
- [3] Joy Arulraj, Matthew Perron, and Andrew Pavlo. Write-behind logging. *Proceedings of the VLDB Endowment*, 10(4):337–348, 2016.
- [4] Philip A Bernstein and Nathan Goodman. Multiversion concurrency control—theory and algorithms. *ACM Transactions on Database Systems (TODS)*, 8(4):465–483, 1983.
- [5] Shimin Chen and Qin Jin. Persistent b+-trees in non-volatile main memory. *Proceedings of the VLDB Endowment*, 8(7):786–797, 2015.
- [6] Justin DeBrabant, Joy Arulraj, Andrew Pavlo, Michael Stonebraker, Stan Zdonik, and Subramanya Dulloor. A prolegomenon on oltp database systems for non-volatile memory. *ADMS@ VLDB*, 2014.
- [7] Xiangyu Dong, Cong Xu, Yuan Xie, and Norman P Jouppi. Nvsim: A circuit-level performance, energy, and area model for emerging nonvolatile memory. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 31(7):994–1007, 2012.



- [8] Maurice P Herlihy and Jeannette M Wing. Linearizability: A correctness condition for concurrent objects. *ACM Transactions on Programming Languages and Systems (TOPLAS)*, 12(3):463–492, 1990.
- [9] Intel. *local/embedded key-value datastore optimized for persistent memory*, accessed June 3, 2020. <https://pmem.io/pmemkv/>.
- [10] Intel. *Persistent Memory Development Kit*, accessed June 3, 2020. <https://pmem.io/pmdk/>.
- [11] Keita Iwabuchi, Hitoshi Sato, Yuichiro Yasui, Katsuki Fujisawa, and Satoshi Matsuoka. Nvm-based hybrid bfs with memory efficient data structure. In *2014 IEEE International Conference on Big Data (Big Data)*, pages 529–538. IEEE, 2014.
- [12] Aasheesh Kolli, Jeff Rosen, Stephan Diestelhorst, Ali Saidi, Steven Pelley, Sihang Liu, Peter M Chen, and Thomas F Wenisch. Delegated persist ordering. In *2016 49th Annual IEEE/ACM International Symposium on Microarchitecture (MICRO)*, pages 1–13. IEEE, 2016.
- [13] Diego Ongaro and John Ousterhout. In search of an understandable consensus algorithm. In *2014 {USENIX} Annual Technical Conference ({USENIX}{ATC} 14)*, pages 305–319, 2014.
- [14] Andrew Pavlo, Gustavo Angulo, Joy Arulraj, Haibin Lin, Jiexi Lin, Lin Ma, Prashanth Menon, Todd Mowry, Matthew Perron, Ian Quah, Siddharth Santurkar, Anthony Tomasic, Skye Toor, Dana Van Aken, Ziqi Wang, Yingjun Wu, Ran Xian, and Tieying Zhang. Self-driving database management systems. In *CIDR 2017, Conference on Innovative Data Systems Research*, 2017.
- [15] Ivy B Peng, Maya B Gokhale, and Eric W Green. System evaluation of the intel optane byte-addressable nvm. In *Proceedings of the International Symposium on Memory Systems*, pages 304–315, 2019.
- [16] David Schwalb, Tim Berning, Martin Faust, Markus Dreseler, and Hasso Plattner. nvm malloc: Memory allocation for nvram. *ADMS@ VLDB*, 15:61–72, 2015.
- [17] Dipanjan Sengupta, Qi Wang, Haris Volos, Ludmila Cherkasova, Jun Li, Guilherme Magalhaes, and Karsten Schwan. A framework for emulating non-volatile memory

systems with different performance characteristics. In *Proceedings of the 6th ACM/SPEC International Conference on Performance Engineering*, pages 317–320, 2015.